

Analizy mikrosymulacyjne - wykłady

Model mikroskopowy I

dr inż. Rafał Kucharski¹

¹Zakład Systemów Komunikacyjnych
Politechnika Krakowska

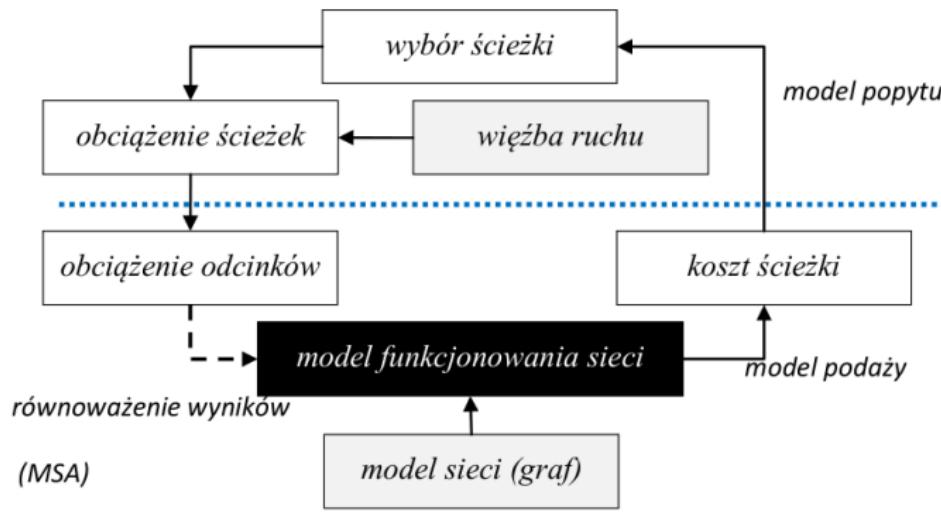
Kraków, 2017



Wstęp

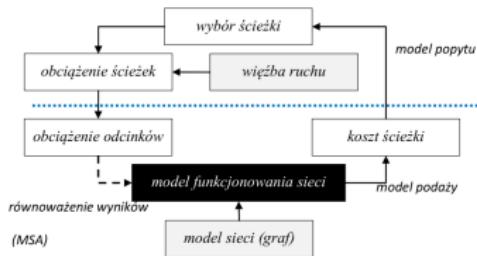
miejsce symulacji w modelowaniu podróży i ruchu

Pełny rozkład ruchu na sieć (ostatni krok modelu czterostadiowego)
np. metoda równowagi **Wardop'a**



Wstęp

miejsce symulacji w modelowaniu podróży i ruchu



W tej pętli iteracyjnej:

- górną część to wybór ścieżki *route-choice model*,
- dolna to model funkcjonowania sieci (*network performance model*), w zależności od modelu:
 - makroskopowy statyczny (Visum i funkcja oporu)
 - makroskopowy dynamiczny (PTV Optima i diagram fundamentalny)
 - symulacja mikroskopowa (PTV Vissim i model Wiedemann)
 - model wieloagentowy (MATSIM i automaty komórkowe)
 - jakikolwiek inny model który określa koszty (czas, długość kolejki, i in.) dla zadanego popytu (obciążenia ścieżek).



Wstęp

rola symulacji mikroskopowej

Symulacja mikroskopowa

dla zadanego popytu $Q_k(t)$ - obciążenie ścieżek k określ koszty przejazdu pojazdów zadanymi ścieżkami

Rozkład ruchu na sieć

dla zadanego popytu $Q_{od}(t)$ - wieźba określ ścieżki generujące koszty spełniające warunki równowagi Wardop'a

$$q_k \cdot (c_k - \tilde{c}_{od})) = 0 \quad (1)$$

$$\tilde{c}_{od} = \min_{k \in K_{od}} (c_k)$$

$$\sum_{k \in K_{od}} q_k = q_{od}$$

(2)



Wstęp

rola symulacji mikroskopowej

Znacznie mniej niż rozkład ruchu

- ① ścieżki (trasy przejazdu) są stałe
- ② brak wpływu zatłoczenia na zmianę trasy
- ③ jak obliczane są trasy przejazdu?
- ④ jak zmiana w organizacji wpłynie na zmianę ścieżek?



Wstęp

symulacja mikroskopowa

Mikrosymulacja ruchu:

- każdy **obiekt** (pojazd α) w **układzie** (sieć drogowa wraz z pojazdami)
- w każdej chwili czasu ($t \in T$)
- podejmuje **decyzje** (o przyśpieszeniu, włączeniu się do ruchu, zmianie pasa, skręcie, ...)
 - subiektywnie **optymalne** (dotrzeć do celu minimalnym kosztem)
 - na podstawie **opisu stanu** (położenie i kierunek mój i innych obiektów w układzie)



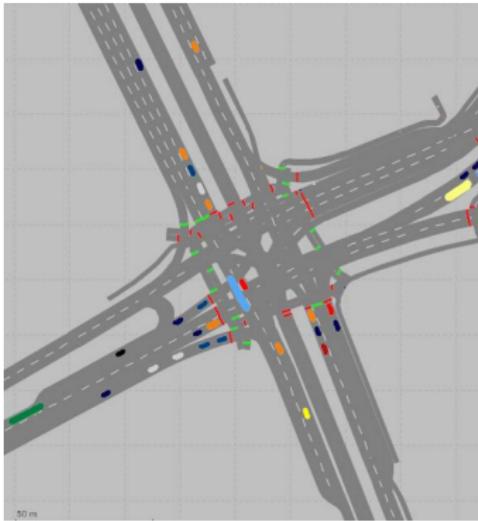
Graf

reprezentacja sieci drogowej



Graf mikroskopowy

reprezentacja sieci



- graf $G(N, A)$, ale dualny, kluczową rolę pełnią relacje skrętne (połączenia między odcinkami)
- odcinki a to jednorodne przekroje pomiędzy miejscami zmiany geometrii
- węzły n to punkty zmian w geometrii (włączenia, przecięcia, rozjazdy, itp.)
- relacje skrętne t to możliwości kontynuacji jazdy pomiędzy odcinkami

wobec tego **położenie** x_α pojazdu jest określone poprzez element grafu na którym znajduje się pojazd w danym czasie, oraz:

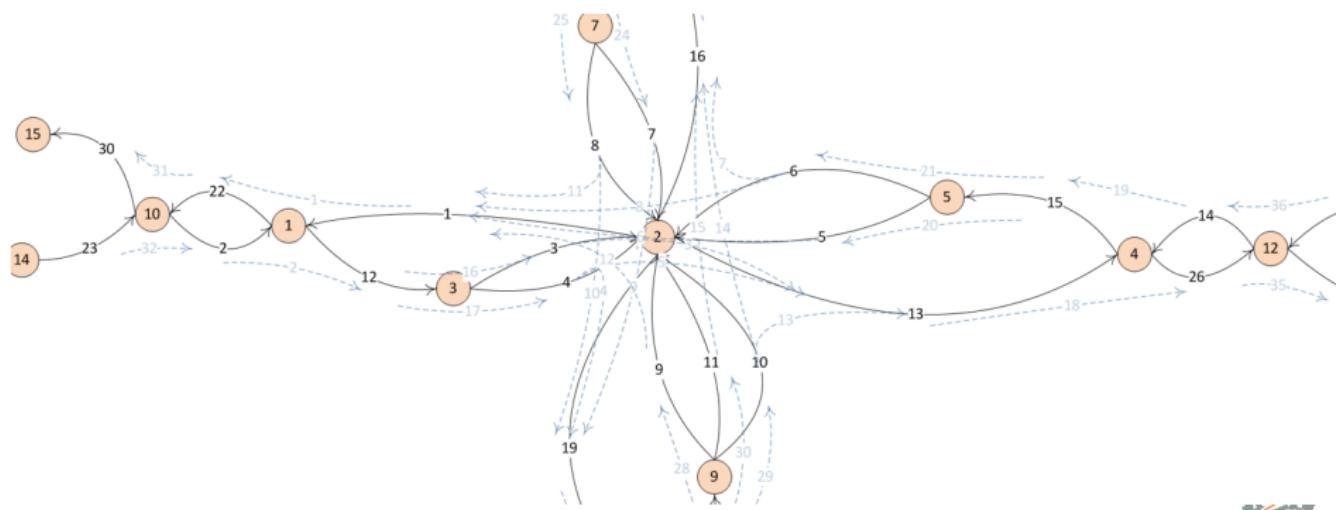
- podłużne $x_\alpha(t) \in R^+$ (rosnie od początku odcinka do końca)
- poprzeczne $n_\alpha(t) \in N(\text{pas})$.



Graf mikroskopowy

graf dualny

$$G(N, A) \rightarrow G(A, T)$$



kluczowe są relacje skrętne a nie odcinki.



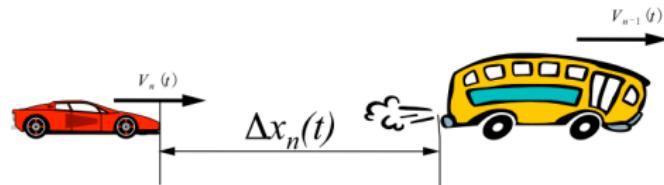
Opis stanu

reprezentacja pojazdów w sieci drogowej



Pojazd (kierowca) mikroskopowy

opis podstawowy



Pojazd α (kierowany przez kierowcę) w danej chwili czasu t opisany jest (zazwyczaj) poprzez :

$x_\alpha(t)$ położenie pojazdu α w czasie t

$v_\alpha(t)$ prędkość

$dv_\alpha(t)/dt$ zmianę prędkości



Pojazd (kierowca) mikroskopowy

opis pełny

Do opisu zachowania kierowcy (pojazdu) potrzebny jest opis stanu jego: α i innych: $\beta \in A$.

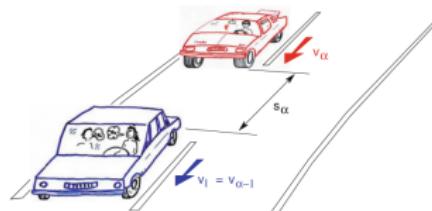
na podstawie których w miarę potrzeb oblicza się:

...



Pojazd (kierowca) mikroskopowy

opis pełny



Do modelowania zmiany położenia podłużnego (*car-following model*) potrzebujemy dodatkowo opisu stanu pojazdu przed nami $x_{\alpha-1}$, jego:

- położenia,
- prędkości

czasami dodatkowo np.

- jego przyśpieszenia dv/dt
- informacji o włączeniu kierunkowskazu,
- świateł stop.

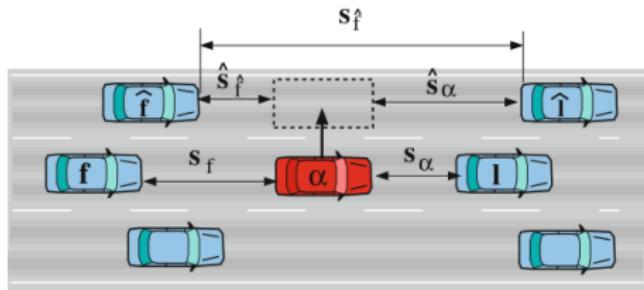
Na podstawie tego obliczany jest odstęp s [m] (*bumber-to-bumper distance*):

$$s_\alpha = x_{\alpha-1} - l_{\alpha-1} - x_\alpha$$



Pojazd (kierowca) mikroskopowy

opis pełny

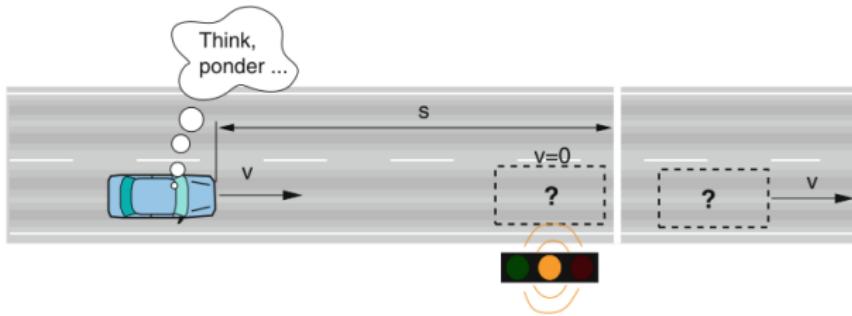


Do modelowania **zmiany pasa** (*lane change*) potrzebujemy dodatkowo opisu stanu pojazdów przed i za nami na naszym pasie i na pasie docelowym (odstępy).



Pojazd (kierowca) mikroskopowy

opis pełny

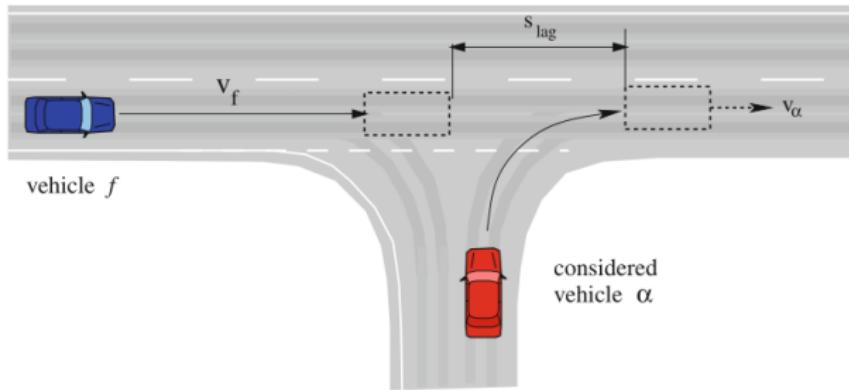


Do decyzji o **zatrzymaniu** na sygnalizacji potrzebujemy odległości do linii zatrzymania s w momencie zmiany fazy.



Pojazd (kierowca) mikroskopowy

opis stanu

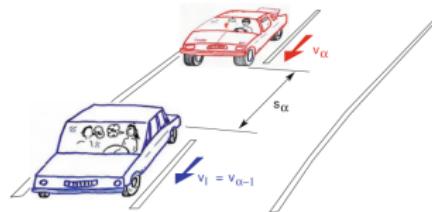


Do decyzji o **włączeniu** się na do ruchu skrzyżowaniu niesygnalizowanym potrzebujemy dodatkowo prędkości i odległości zbliżającego się pojazdu.



Pojazd (kierowca) mikroskopowy

opis stanu



Kierowca (i pojazd) α w danej chwili czasu t znajduje się w sytuacji (stanie) opisanej przez zmienne stanu, np.:

$$(s_\alpha(t), v_\alpha(t), \dots)$$

dobór zmiennych zależy od rodzaju modelu i decyzji jaka jest podejmowana



Implementacja

algorytmy numeryczne symulujące ruch pojazdów



Rodzaje implementacji

modele ciągłe i dyskretne

modele analityczne mogą być ciągłe - opisane są równaniami różniczkowymi i mogą być obliczone dla dowolnej chwili czasu t , w szczególności dla całego okresu symulacji $t \in T$.

Po prostu rozwiązuje się równanie różniczkowe¹:

$$\dot{v}_\alpha(t) = a_{mic}(s_\alpha, t_\alpha, v_l)$$

ale komputery są binarne a nie ciągłe, wobec czego wszystkie implementacje na pewnym etapie muszą być zdyskretyzowane $t \in [0, 1 \cdot \Delta t, 2 \cdot \Delta t, \dots, t \cdot \Delta t]$:

$$\dot{v}_\alpha(t + \Delta t) = a_{mic}(s_\alpha(t), v_\alpha(t), v_l(t))$$

określamy stan układu w kroku $t + \Delta t$ na podstawie stanu w kroku t .



¹ gdzie a_{mic} to rezultat uzyskany z modelu mikroskopowego, który określmy później.

Rodzaje implementacji

modele ciągłe i dyskretne

W implementacjach komputerowych (algorytmy) określamy stan układu w kroku $t + \Delta t$ na podstawie stanu w kroku t . Dwie możliwości:

① $v_\alpha(t + \Delta t) = f(t)$

proste rozwiązanie (symulacja krok po kroku)

② $v_\alpha(t + \Delta t) = f(t + \Delta t)$

kłopot (iteracyjne rozwiązanie w każdym kroku) (zagadnienie punktu stałego $x = f(x)$).

Zazwyczaj mamy układ równań dolnoprzekątniowych, który można rozwiązać sekwencyjnie.



Algorytm

ogólny, dyskretny model mikrosymulacyjny

Input: graf, dopływ pojazdów α z przypisaniem do ścieżek k

begin

$t \leftarrow 0$

if $t \leq T$ **then**

generuj dopływ pojazdów (na podstawie popytu i rozkładów p-wa na poszczególnych wlotach)

$\alpha \leftarrow 0$

while $\alpha < A$ **do**

określ położenie pojazdu $x_\alpha(t)$ - CFM, lane-change, gap acceptance

if koniec odcinka **then**

przejdź na kolejny odcinek na ścieżce k

end

$\alpha \leftarrow \alpha + 1$ kolejny pojazd

end

$t \leftarrow t + 1$ kolejny krok czasu

end

Output: trajektorie pojazdów $X \leftarrow \{x_\alpha(t) : \alpha \in A\}$

opcjonalnie: opracuj dodatkowe wyniki^a

end

^a np. straty czasu, długości kolejek, liczby zatrzymań



Narzędzia

przegląd

① komercyjne:

- ① Synchro
- ② Aimsun
- ③ Paramics
- ④ VISSIM
- ⑤ ...

② badawcze

- ① MATSim
- ② dynaMIT
- ③ SUMO
- ④ Mezzo
- ⑤ Intelligent Driver Model ²
- ⑥ Paweł Gora - *Traffic Simulation Framework* ³
- ⑦ ...

² <http://www.traffic-simulation.de>

³ <https://www.mimuw.edu.pl/~pawelg/indexpl.html>



Decyzje kierowcy

przyśpiesz, zwolnij, zmień pas, czekaj, stój



Decyzje kierowcy

kierowca podejmuje **decyzje** na podstawie opisu stanu:

- swojego ($v_\alpha, x_\alpha, a_\alpha$)
- innych pojazdów (odległości, różnice prędkości)
- przeszkód (np. czerwone światło)



Decyzje kierowcy

rodzaje decyzji

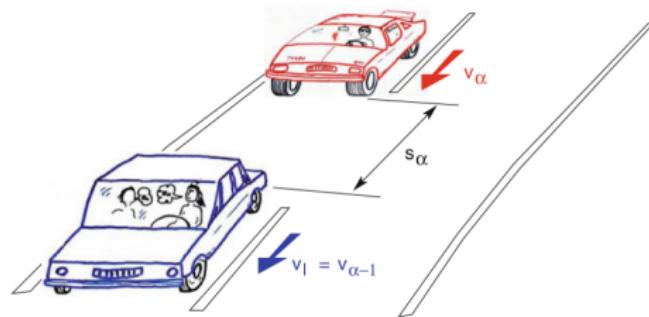


Fig. 10.1 Defining the state variables of car-following models

- podążanie za liderem
 - zmiana pasa
 - włączenie się do ruchu

ciągła decyzja o przyśpieszeniu lub hamowaniu

dyskretna decyzja o położeniu poprzecznym

dyskretna decyzja ruszam/czekam, zatrzymuję się/jadę



Podążanie za liderem

opis

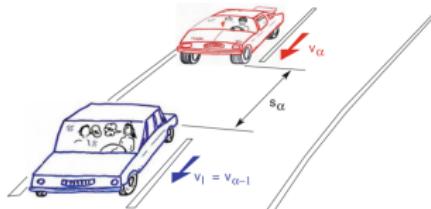


Fig. 10.1 Defining the state variables of car-following models

Zmienne decyzyjne to **przyśpieszenie** $\dot{v}_\alpha(t)$, $a_\alpha(t)$.

W ujęciu dyskretnym określam prędkość w kolejnym kroku $t + \Delta t$ na podstawie aktualnego opisu stanu:

$$v_\alpha(t + \Delta t) = v_{mic}(s_\alpha(t), v_\alpha(t), v_l(t))$$

Położenie x_α jest zazwyczaj interpolowane:

$$x_\alpha(t + \Delta t) = x_\alpha(t) + \frac{v_\alpha(t) + v_\alpha(t + \Delta t)}{2} \Delta t$$



Podążanie za liderem

stan równowagi *cruise*

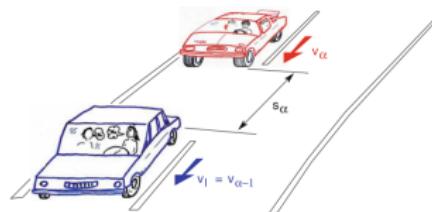


Fig. 10.1 Defining the state variables of car-following models

wszystkie pojazdy jadą z tą samą prędkością w takich samych odstępach i nie przyśpieszają

$$\begin{aligned}v_\alpha &= v_\beta : \forall \alpha, \beta \in A \\s_\alpha &= s_\beta : \forall \alpha, \beta \in A \\a_\alpha &= 0 : \forall \alpha \in A\end{aligned}$$



Podążanie za liderem

stan nierównowagi

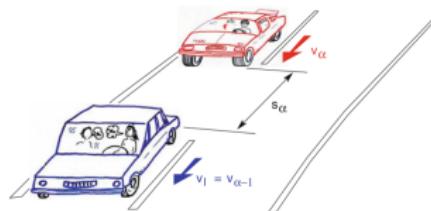


Fig. 10.1 Defining the state variables of car-following models

konieczność decyzji o zmianie prędkości, np.
Intelligent Driver Model (IDM)

$$\dot{v} = a \left[1 - \left(\frac{v}{v_0} \right)^\delta - \left(\frac{s^*(v, \Delta v)}{s} \right)^2 \right]$$

$$s^*(v, \Delta v) = s_0 + \max \left(0, vT + \frac{v\Delta v}{2\sqrt{ab}} \right)$$



Podążanie za liderem

IDM

$$\dot{v} = a \left[1 - \left(\frac{v}{v_0} \right)^\delta - \left(\frac{s^*(v, \Delta v)}{s} \right)^2 \right]$$

$$s^*(v, \Delta v) = s_0 + \max \left(0, vT + \frac{v\Delta v}{2\sqrt{ab}} \right)$$

gdzie:

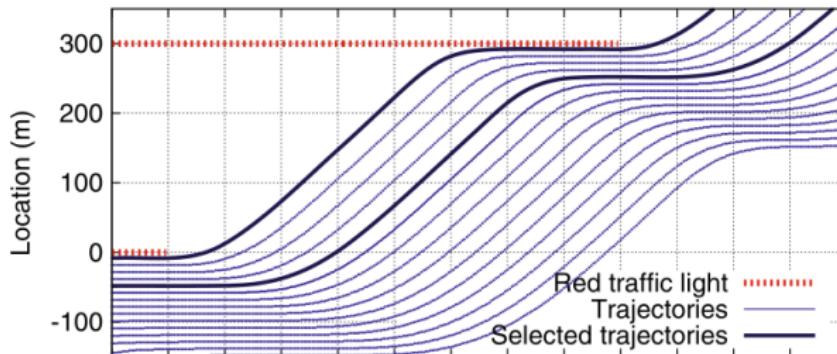
parametr	opis	typowa wartość (zamiejska)	(miejiska)
v_0	pożądana prędkość	120km/h	54 km/h
δ	parametr profilu przyśpieszenia	4	4
s_0	minimalny odstęp	2m	2m
a	przyśpieszenie	$1m/s^2$	$1m/s^2$
b	opóźnienie	$1.5m/s^2$	$1.5m/s^2$
T	czas reakcji	1s	1s



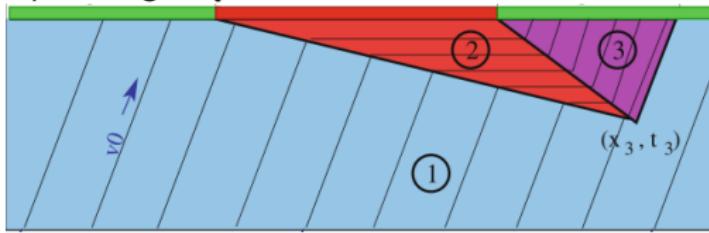
Podążanie za liderem

IDM - wyniki

IDM



vs. model pierwszego rzędu



Podążanie za liderem

Model Wiedemann'a

Model opisuje psychofizyczne zachowanie kierowcy w czterech reżimach:

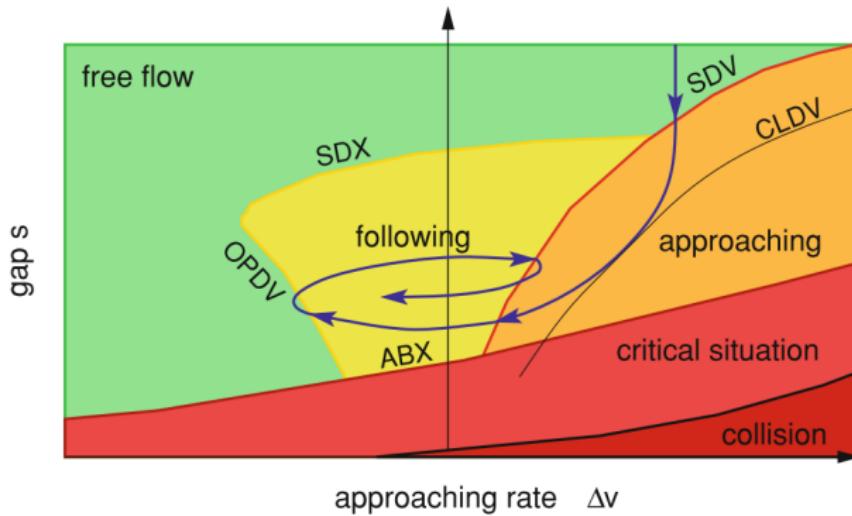
- ① ruch niezakłócony
- ② zbliżanie się do wolniejszego pojazdu
- ③ podążanie za liderem (nie ma pełnej równowagi, są ciągłe oscylacje)
- ④ krytyczne sytuacje wymagające hamowania.

w każdym z nich używane są inne funkcje: $a_\alpha = a_{mic}(s, v, \Delta v)$.



Podążanie za liderem

Model Wiedemann'a - wykres reżimów



SDV
CLDV
OPDV
ABX
SDX

próg czułości (zaczynam zwalniać)
optymalny odstęp (do takiej odległości chcę zwolnić)
próg rozjeżdżania (zaczynam przyśpieszać)
minimalny (ściśle) odstęp przy podążaniu za liderem
maksymalny (nie ściśle) odstęp przy podążaniu za liderem



Podążanie za liderem

Dostępne modele

- Optimal Velocity Model
- Newell's Car Following Model
- Gipp's Model
- Intelligent Driver Model
- Wiedemann Model
- Nagel-Schreckenberg Model
- Barlovic Model
- ...



Sytuacje dyskretne

wybór opcji



Sytuacje dyskretne

ogólnie

Kierowca wybiera opcję k spośród dostępnych opcji K .

Opcje:

- ① zmiana pasa: zostań/zmień
- ② zatrzymanie na światłach: zatrzymuj się/przejedź
- ③ wlot podporządkowany: czekaj/jedź.

Wybór jest ograniczony przez **kryterium bezpieczeństwa**, tj. żaden inny kierowca β nie powinien w wyniku naszej decyzji k być zmuszonym do hamowania z przyśpieszeniem większym niż b_{safe} (ok. $2m/s^2$):

$$\alpha(\beta, k) < b_{\text{safe}}$$

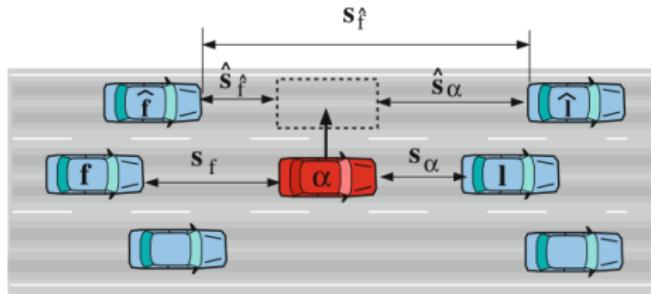
Wybiera w oparciu o kryterium największej (**subiektywnej**) użyteczności $U^{\alpha, k}$:

$$k^* = \operatorname{argmax}_{k \in K} U^{\alpha, k}$$



Zmiana pasa

kryterium z IDM

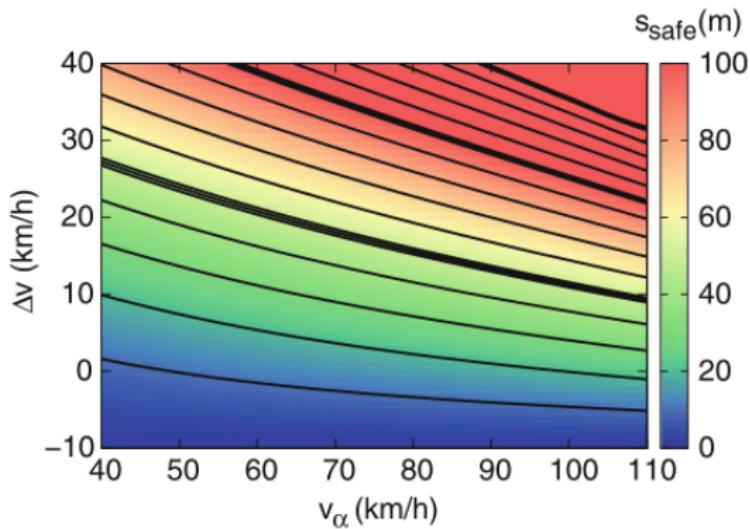


Sprawdź czy odstęp na sąsiednim pasie $s_{\hat{f}}$ jest wystarczający. Np. (IDM):

$$s_{\hat{f}} > s_{\text{safe}}^{\text{IDM}} = \frac{s^*(v_{\hat{f}}, v_{\hat{f}} - v_{\alpha})}{\sqrt{\frac{b_{\text{safe}}}{a}}}$$



Zmiana pasa kryterium z IDM

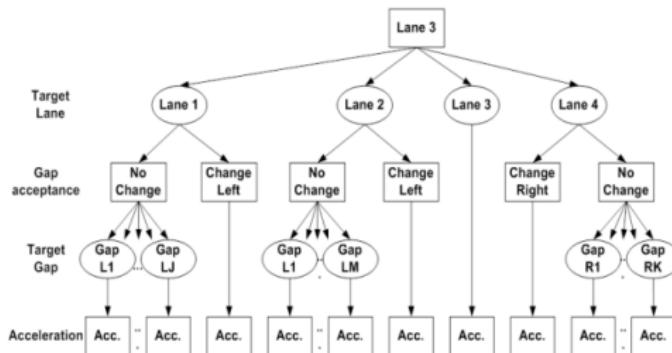
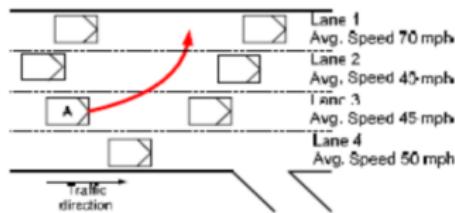


wartości bezpiecznego odstępu w zależności od prędkości v i różnicy prędkości Δv obliczone w IDM.



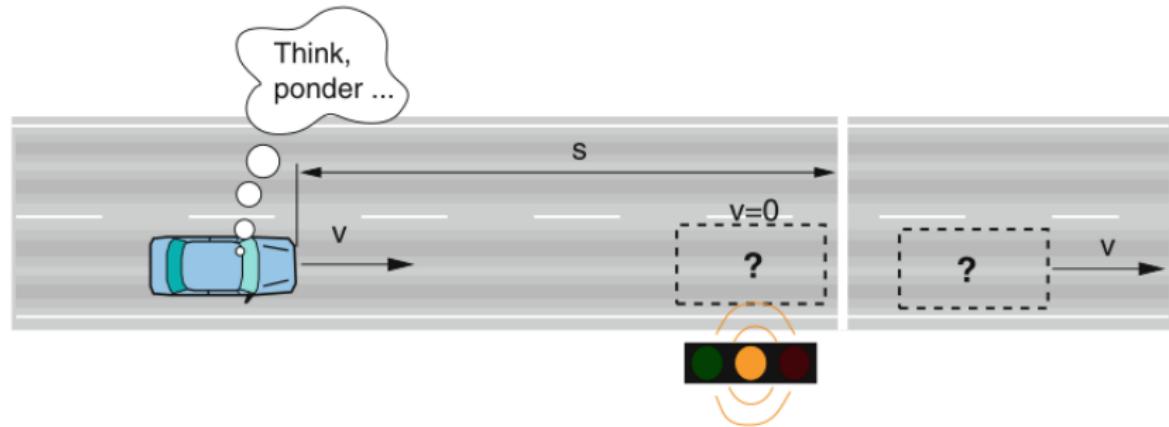
Zmiana pasa

model ogólny



Zatrzymanie się na światłach

kryterium z IDM



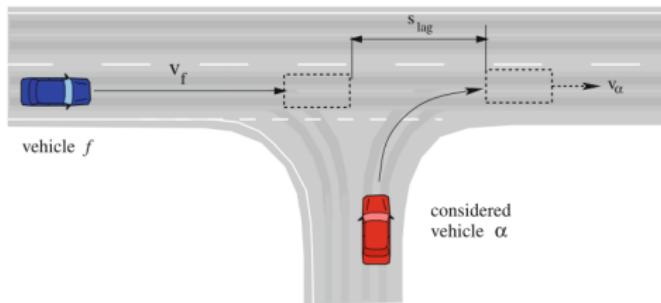
jedź⁴
stój

jeśli $a_\alpha < -b_{\text{safe}}$
w przeciwnym wypadku

⁴jeśli musiałbyś hamować z opóźnieniem większym niż b_{safe}

Włączanie się do ruchu

kryterium z IDM



Tutaj można stosować kryterium zmiany pasa odpowiednio podmieniając zmienne.

włącz się
poczekaj

jeśli $s_{lag} > s_{sefe}$
w przeciwnym wypadku



Zachowanie kierowcy

szacowanie zmiennych stanu, reakcje, decyzje



Zachowanie kierowcy

charakterystyka

Kierowca w rzeczywistości:

- ① ma skończony (dodatni) czas reakcji,
- ② popełnia błędy w ocenie sytuacji (np. przeszacowuje odległość),
- ③ ma zdolności strategiczne (potrafi przewidzieć sytuacje i zareagować na nią z wyprzedzeniem),
- ④ odczytuje sygnały od innych kierowców (klaskon, kiwnięcie głowa, brzydkie słowo, niepewny tor jazdy, ...),
- ⑤ buduje swoją długofalowa strategie (po kilku latach stania w korku ma swoje techniki - subiektywnie optymalne),
- ⑥ niewrażliwość na małe zmiany $\Delta v \sim 0$ jest niezauważalna,
- ⑦ jest uprzejmy i dba o innych, lub wręcz przeciwnie (system kooperacyjny o quasi-globalnym optimum, albo *user-optimum*),



Zachowanie kierowcy

reakcja

Kierowca **reaguje** na zmiany stanu ruchu drogowego, ale reakcja trwa (T_r).

Proces reakcji kierowcy, $T_r = \sum$:

- ① reakcja mentalna:
„widzę obiekt na drodze” → „rozpoznaję, że to człowiek” → „identyfikuję zagrożenie” → „wybieram optymalną decyzję” → „hamuję/skręcam/nic nie robię”
- ② czas czynności:
ruch nogą do hamulca, mocniejsze ściśnięcie kierownicy, odstawienie kawy
- ③ czas reakcji pojazdu:
zależny od systemu układu hamulcowego czas na faktyczne rozpoczęcie hamowania.

Wobec tego podstawowe równanie:

$$\dot{v}_\alpha(t + \Delta t) = a_{mic}(s_\alpha(t), v_\alpha(t), v_l(t))$$

przyjmuje bardziej realistyczną postać:

$$\dot{v}_\alpha(t + \Delta t) = a_{mic}(s_\alpha(t - T_r), v_\alpha(t - T_r), v_l(t - T_r))$$



Zachowanie kierowcy

błędy w ocenie sytuacji

Opis stanu (własnego i innych pojazdów) jest subiektywny. Zależy od kierowcy i może być błędny, dlatego w rzeczywistości kierowca podejmuje decyzje na podstawie subiektywnych wartości zmiennych stanu, a nie obiektywnych

$$s_\alpha(t) \rightarrow s_\alpha^{est}(t)$$



Zachowanie kierowcy

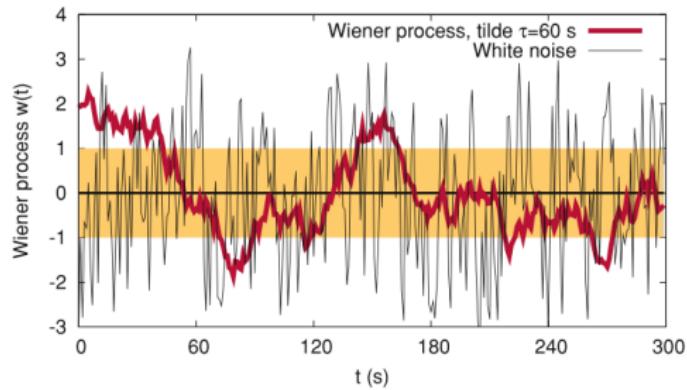
błędy w ocenie sytuacji

Błąd $|s_\alpha(t) - s_\alpha^{est}(t)|$ jest zmienną losową.

W najprostszym przypadku może być opisany rozkładem normalnym:

$$|s_\alpha(t) - s_\alpha^{est}(t)| \sim N(0, 1)$$

W bardziej realistycznym opisie może to być np. proces Wienera⁵

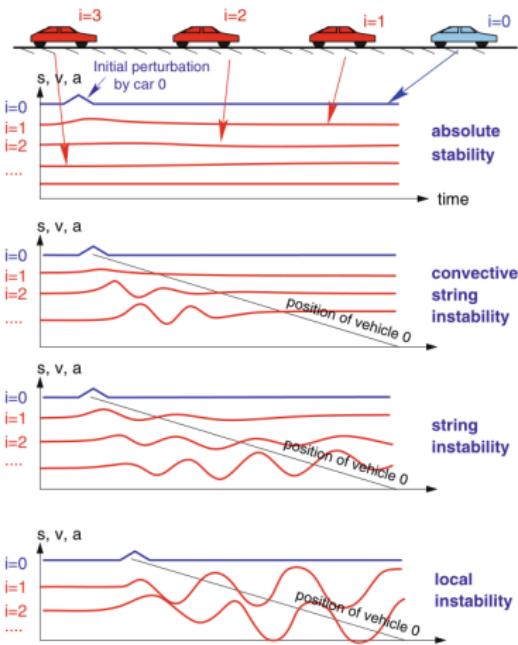


⁵ czyli losowość ale o spójnym przebiegu w czasie. Przy użyciu wprost rozkładu normalnego (biały szum) kierowca może w chwili t przeszacować, a w chwili $t + \Delta t$ niedoszacować, proces Wienera jest bardziej spójny i kierowca albo konsekwentnie niedoszacowuje albo konsekwentnie przeszacowuje.

Zachowanie kierowcy

powstawanie stop & go wave

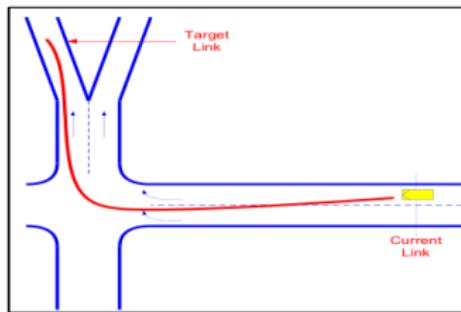
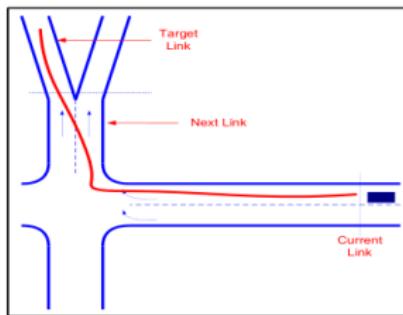
zaburzenie płynności
pierwszego pojazdu eskaluje i
powoduje coraz większe
oscylacje



Zachowanie kierowcy

przewidywanie

Kierowca przewiduje na kilka kroków wprzód. Jak to uwzględnić w modelu mikroskopowym? (otwarte pytanie **MITSIM**)



źródło: M. Ben-Akiva, MIT Course 2014

kierowca nieprzewidujący (z lewej) i przewidujący (z prawej)



Wyniki symulacji

jak je przedstawić, interpretować i używać



Wyniki symulacji pierwotne

ogólnie: $\{x_\alpha(t) : \alpha \in A, t \in T\}$

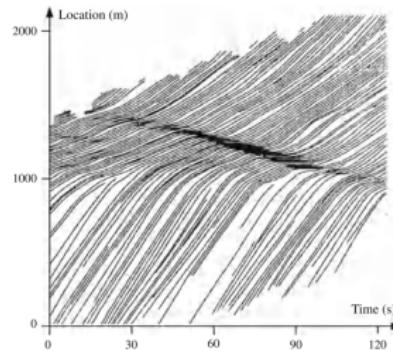


Fig. 2.1 Trajectories with moving stop-and-go waves on a British motorway segment [Adapted from: Treiterer et al. (1970)]

zbiór pełnych trajektorii wszystkich pojazdów



Wyniki symulacji

przetworzone

na podstawie trajektorii można określić następujące miary mikroskopowe:

- czas przejazdu pomiędzy zadanymi punktami.
- liczba zatrzymań
- prędkość
- strata czasu (czas z zatrzymaniami minus czas bez zatrzymań).
- emisja
- ...

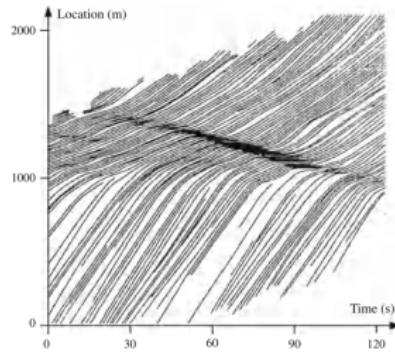


Fig. 2.1 Trajectories with moving stop-and-go waves on a British motorway segment [Adapted from: Treiterer et al. (1970)]



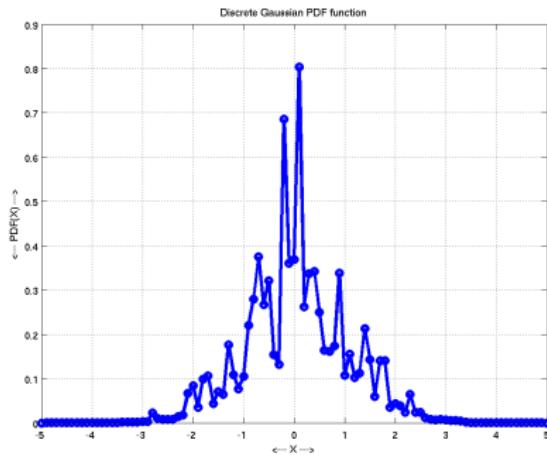
Wyniki symulacji

wyniki makro (zagregowane)

Wyniki mikro możemy agregować do rozkładu zmiennej losowej (średnia, kwantyle, maksymalne i minimalne), np:

- czas przejazdu
- długość kolejki
- straty czasu

itp.

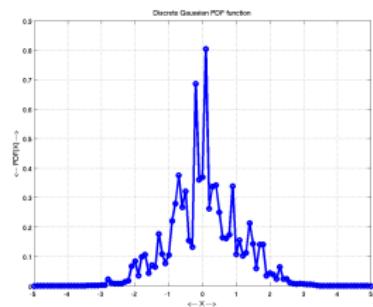


Wyniki symulacji

interpretacja

np. długość kolejki:

- średnia z symulacji:
 - średnia z całej symulacji
 $\bar{l}_t : t \in T$
 - średnia z symulacji bez początków i końców
(*warm-up, cool-down*):
 $\bar{l}_t : t \in T'$
 - maksimum, mediana, kwantyl (jaki?)
 - odchylenie standardowe
- średnia z kilku symulacji
 - średnia ze średnich z kilku symulacji
 - średnia z kwantylem z kilku symulacji



Wyniki symulacji

liczba symulacji

Podstawowe narzędzia statystyki: dobór liczebności próby n dla oszacowania rozkładu zmiennej losowej.

- określamy charakterystykę, którą chcemy oszacować (np. czas przejazdu, długość kolejki)
- czy interesuje nas średnia, odchylenie, czy kwantyl?
- określamy przedział i poziom ufności α np. d na poziomie ufności $\alpha = 90\%$ - z odwrotnej dystrybuanty rozkładu normalnego.
- wykonujemy kilka (n) symulacji i obliczamy odchylenie standardowe σ interesującej nas charakterystyki

liczba replikacji:

$$n \geq u_{1-\alpha/2}^2 \cdot \frac{\sigma^2}{d^2}$$

zazwyczaj kilkadziesiąt



Wyniki symulacji graficzne



źródło: AIMSUN

kolorowanie grafu zgodnie z wartością charakterystyki:

- prędkość (średnia, dolny kwantyl, odchylenie, ...)
- potok (poj./s)
- długość kolejki
- czas przejazdu
- gęstość
- emisja
- ...

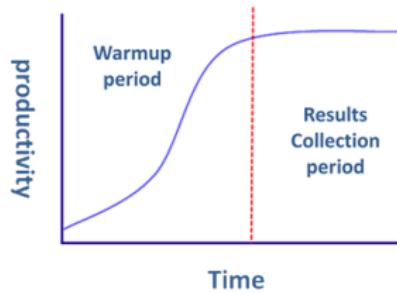
i ich ewolucja w czasie: $\cdot(t)$



Wyniki symulacji

zakres czasowy

Sieć musi się rozgrzać (**warm-up**) i dopiero z rozgrzanej sieci możemy zbierać wyniki.



źródło: Simul8.com

Np. Gdy chcemy symulować godzinę szczytu porannego (8-9) to symulacja nie może się zacząć od pustej sieci, bo sieć przed ósmą nie jest pusta (są kolejki, mniejsze ale są)



Wyniki symulacji

zakres czasowy

Zazwyczaj chcemy uzyskać wyniki symulacji dla godziny (np. szczytu porannego 8 – 9), ale co to znaczy w modelu dynamicznym?

Możliwe interpretacje godziny szczytu:

- pojazdy generowane pomiędzy 8 – 9 i tylko te pojazdy są symulowane, mogą dojechać później.
- pojazdy generowane pomiędzy 8 – 9 przy czym wszystkie pojazdy są symulowane również te wyjeżdżające wcześniej i później.
- części trajektorii wszystkich pojazdów pomiędzy 8 – 9 (tylko części trajektorii są brane pod uwagę)
- pojazdy przejeżdżające przez analizowany obszar pomiędzy 8 – 9 w tym te które rozpoczęły podróż wcześniej (tylko części trajektorii są brane pod uwagę i tylko w obszarze).

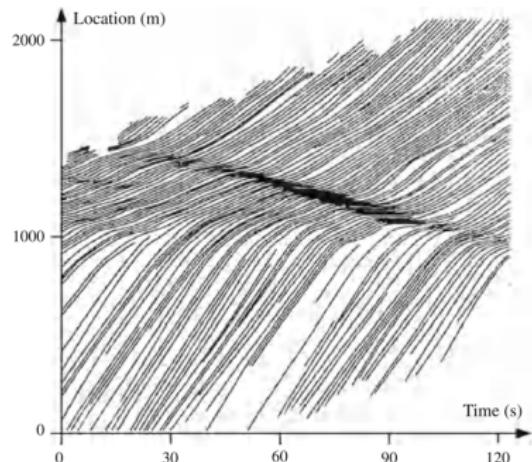


Fig. 2.1 Trajectories with moving stop-and-go waves on a British motorway segment [A] from: Treiterer et al. (1970)]

Kalibracja

zgodność modelu z rzeczywistością



Kalibracja

kalibracja to proces ustalenia postaci i parametrów modelu. Jego celem jest maksymalizacja zgodności modelu z rzeczywistością.

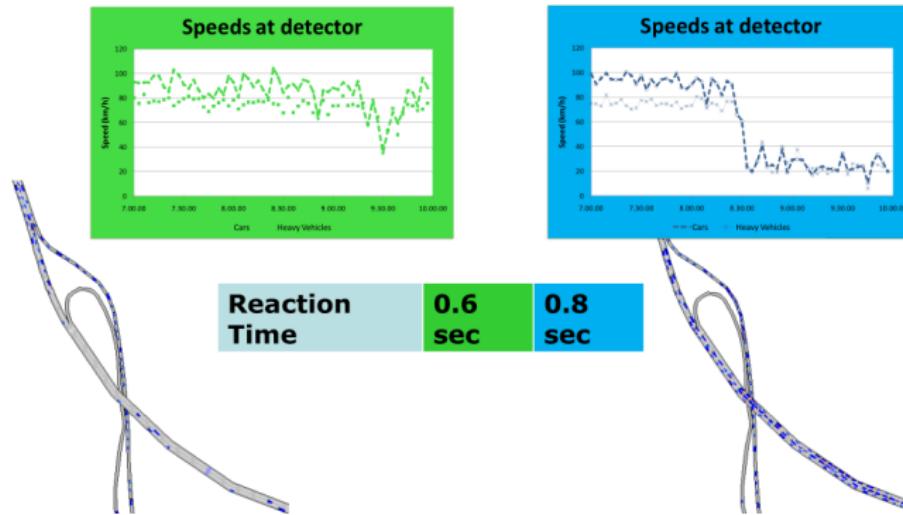
rzeczywistość musimy mieć zaobserwowaną: zmierzoną i opisaną (np. zapis wideo, pętle indukcyjne, pojazdy sondujące, długości kolejek).
zgodność musimy mierzyć i maksymalizować → problem optymalizacyjny.



Kalibracja

znaczenie

np. przeszacowanie czasu reakcji



źródło: V. Punzo, MIT Course 2014



Kalibracja

problem optymalizacyjny

Dopasowanie:

$$S(\beta) = \sum_{i=1}^n ||y_i^{sim}(\beta) - y_i^{data}(\beta)||$$

gdzie:

S to miara dopasowania

β to wektor parametrów modelu

n to liczba obserwacji

y_i^{sim} to wynik modelu

y_i^{data} to wynik pomiaru

$|||$ to ogólna miara dopasowania (np. SSE, MSE, RMSE, $(x - \hat{x})^2$, ...)

Problem optymalizacyjny:

$$\hat{\beta} = \operatorname{argmin}_{\beta} S(\beta)$$

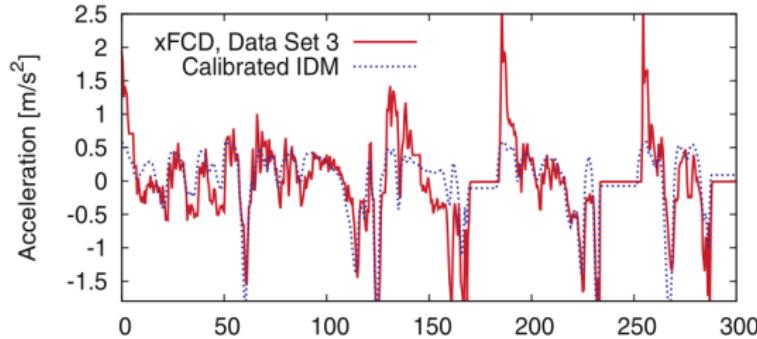


Kalibracja

dopasowanie modelu w skali mikro

zgodność rzeczywistego zjawiska (w skali mikro) z modelowanym (w skali mikro)

profil przyśpieszenia pojedynczego pojazdu $\dot{v}_\alpha(t)$:



Kalibracja

dopasowanie modelu w skali mikro

wyniki kalibracji modelu **parametryzacja:**

wartości parametrów i rozkładów.

Car-following model		
Parameter	Acceleration	Deceleration
Sensitivity parameter	0.0225	-0.0418
Subject speed	0.722	-
Leader spacing	0.242	0.151
Density	0.682	0.804
Leader relative speed	0.600	0.682
Error term	$\sim N(0, 0.825^2)$	$\sim N(0, 0.802^2)$
Free-flow model		
Parameter	Value	
Sensitivity parameter	0.309	
Desired speed constant	3.28	
Leader speed	0.618	
Heavy vehicle dummy	-0.670	
LOS A dummy	7.60	
Error term	$\sim N(0, 1.13^2)$	
Headway threshold distribution		
Truncated normal distribution		$\sim(3.17, 0.870^2)$
Truncation bounds (sec.)		[0.5, 6.0]
Reaction time distribution		
Truncated log normal distribution		$\sim(0.272, 0.212^2)$
Truncation bounds (sec.)		[0, 3.0]

źródło: Ahmed, 1999

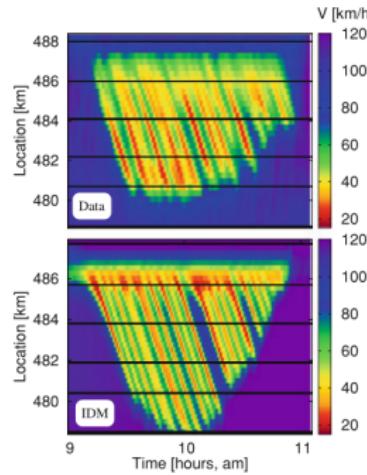


Kalibracja

dopasowanie modelu w skali makro

zgodność rzeczywistego stanu sieci (w skali makro) z modelowanym (w skali makro)

wykres droga-prędkość-czas:

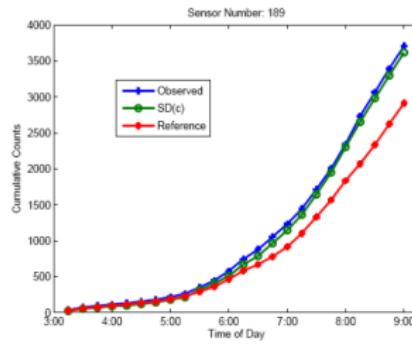


Kalibracja

weryfikacja ogólna

zgodność wartości globalnych:

np. liczba pojazdów N



źródło: M. Ben-Akiva, MIT Course 2014



Sygnalizacja i sterowanie w modelowaniu mikroskopowym

kontrola przepływu pojazdów



Sygnalizacja w modelowaniu mikroskopowym

sposób odwzorowania

w trzonie modelu sytuacja jest **zerojedynkowa**:

czerwone stój

zielone jedź

$$\dot{v}_\alpha(t) = a_{mic}(s_\alpha, t_\alpha, v_l, \textit{signal})$$

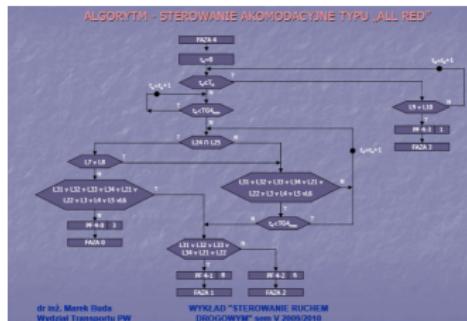
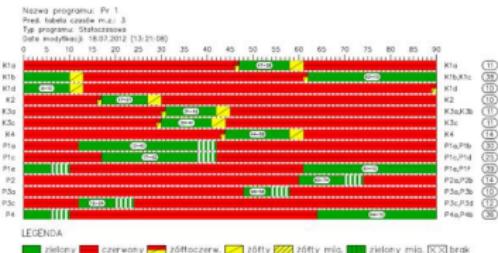
w praktyce to kilka linii kodu w algorytmie bazowym



Sygnalizacja

upraszczanie

Po stronie samego modelu nie ma znaczenia jaki i jak bardzo skomplikowany jest plan sygnalizacji.



i tak upraszczamy go do informacji przekazanej kierowcy: zielone|czerwone



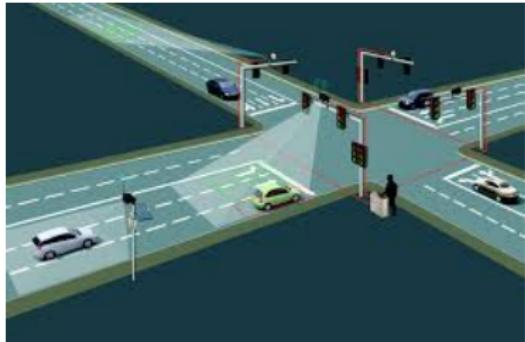
Sterowanie

realistyczny model

dzięki realizmowi modelu mikroskopowego nie potrzebujemy metod do odwzorowania systemów sterowania, po prostu budujemy je identyczne jak w rzeczywistości.

co więcej modele mikroskopowe stosujemy jako środowiska do testowania systemów zarządzania, sygnalizacji akomodacyjnej, koordynacji, itp.

ale to nie jest element symulacji mikroskopowej.



Sterowanie

możliwości zastosowania modelu

model symuluje przepływ pojazdów (kierowców w pojazdach) przez sieć.
możemy symulować np.:

- wpływ znaków zmiennej treści na trasę
- testować sterowanie obszarowe
- testować priorytetowanie (uprzywilejowane, komunikacja zbiorowa)
- testować pojazdy autonomiczne
- badać wpływ aplikacji mobilnych (nawigacja w czasie rzeczywistym)
- kooperacje pomiędzy pojazdami autonomicznymi
- minimalizować emisję
- itp.



Popyt

odzwierciedlenie przepływu pojazdów przez sieć



Popyt

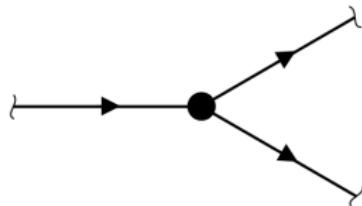
generacja pojazdów

Dwie opcje:

- **explicit:** ścieżki k i popyt na nich q_k



- **implicit:** generacja na wlocie q_a i rozploty w punktach decyzyjnych $r_a(t)$



Popyt

pojazdy podążające po ścieżkach



- sekwenca odcinków:

$$k = \{a_1, a_2, \dots, a_n\}$$

- sekwenca relacji skrętnych:

$$k = \{t_1, t_2, \dots, t_n\}$$

- potok na ścieżce q_k [poj./h]



Popyt

pojazdy podążające po ścieżkach



Związek z modelem makroskopowym:

Popyt w więźbie q_{od} przemnożony p-wo wyboru ścieżki p_{od}^k

$$q_k = q_{od} \cdot p_{od}^k$$



Popyt

generacja pojazdów

Zadajemy całkowitą liczbę pojazdów q na ścieżce q_k , albo na wlocie q_a . Zazwyczaj w pojazdach na godzinę.

Na tej podstawie generowany jest proces dopływu pojazdów:

$$q_k \rightarrow \{t_1, t_2, \dots, t_{q_k}\}$$

Gdzie odstępy $t_n - t_{n-1}$ są

- stałe (model deterministyczny)
- zmienne (model stochastyczny)

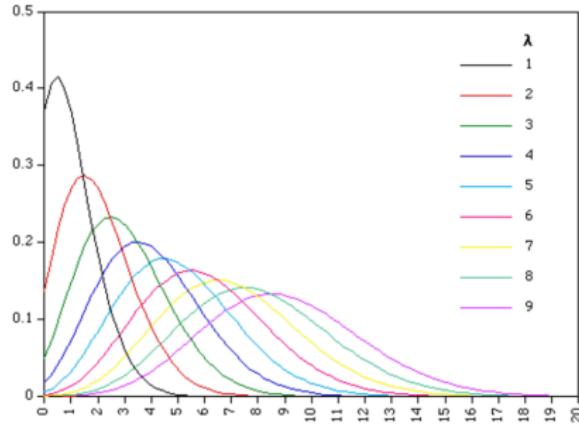


Popyt

stochastyczna generacja pojazdów

Odstępy $\Delta t = t_n - t_{n-1}$ są zazwyczaj losowane z rozkładu Poissona

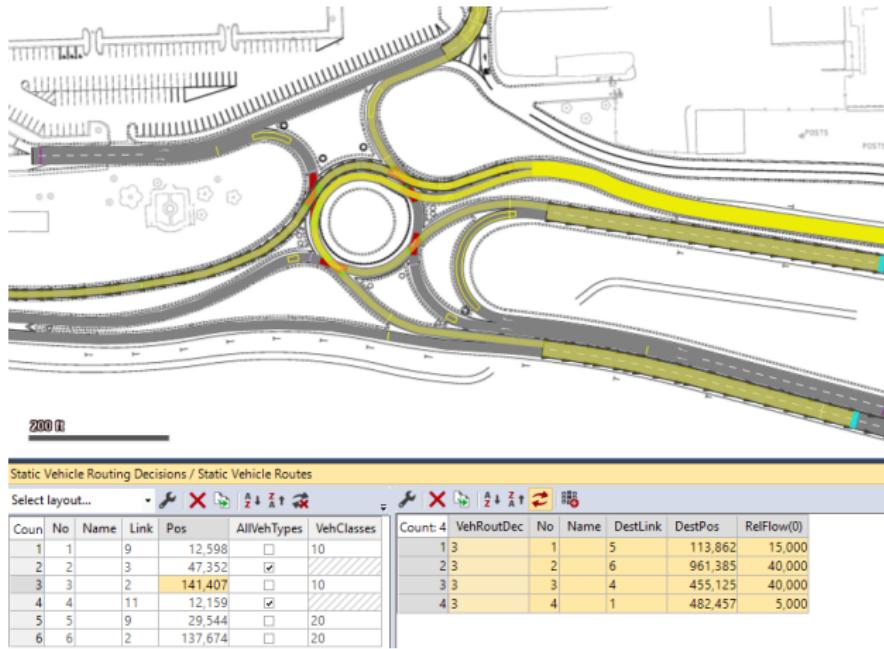
$$p(\Delta t) = \frac{\lambda^{\Delta t} e^{-\lambda}}{\Delta t!}$$



zazwyczaj generowane jest tyle samo pojazdów co zadano $\sum_{\Delta t \in q_k} p(\Delta t) = q_k$ ale trzeba pamiętać, że liczba generowanych pojazdów też jest zmienną losową.

Popyt

przypis do ścieżek



VehicleInput → *Volume*; *VehRoutDec(VehicleInput)* → *RelFlow*

Popyt

Granice modelu

Pojazdy dopływają do modelu zgodnie z rozkładem Poisson'a, co jest rzadko zgodne z rzeczywistością. Zazwyczaj:

- w ruchu zamiejskim jednopasowym tworzą się kolumny (*platoon*) pojazdy szybsze dojeżdżają do wolniejszych
- w ruchu zamiejskim wielopasowym zatłoczonym kolumny segregują się, mogą tworzyć się *stop-ad-go waves*, kolumny powstałe po wyprzedzających ciężarówkach itp.
- w ruchu miejskim sterowanym pojazdy zatrzymują się przed sygnalizatorem tworzą kolumnę i ruszają z natężeniem nasycenia w rozpraszających się kolumnach.

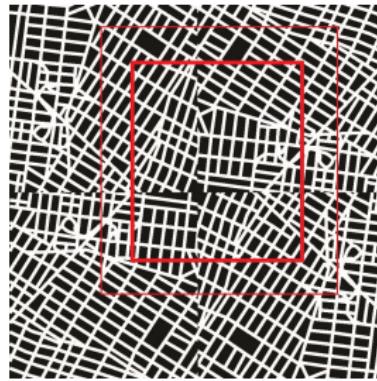
Dopływ Poisson'owski można stosować bezpośrednio na granicy obszaru tylko dla:

- ruchu zamiejskiego o niewielkim zatłoczeniu (prędkość swobodna)
- ruchu miejskiego niesterowanego o niewielkim zatłoczeniu (prędkość swobodna)



Popyt

Granice modelu



W każdym innym przypadku dopływ Poissonowski można stosować na granicy poszerzonego modelu. Dopływ swobodny zostanie *przefiltrowany* przez skrzyżowania graniczne i do obszaru wpłynie już potok o innym rozkładzie (w kolumnach).

rule of thumb: dwa skrzyżowania przed wjazdem do obszaru powinny wystarczająco przefiltrować dopływ poissonowski



Dziękuję za uwagę
zapraszam do dyskusji

źródła wszystkich obrazów (jeśli nie podano inaczej)
M. Treiber, A. Kesting Traffic Flow Dynamics, Springer 2013, lub własne

